

Estatística descritiva

Covariância e Correlação Linear

Fabio Cop (fabiocopf@gmail.com)





Instituto do Mar - UNIFESP

Última atualização em 06 de janeiro de 2022


Conteúdo da aula

1. Medindo a intensidade de associações lineares
 2. Soma dos Quadrados e Variância Amostral
 3. Soma dos Produtos Cruzados e Covariância
 4. O coeficiente de Correlação Linear de Pearson (r)
 5. Associações Lineares e Causalidade
 6. Os comandos em R
-


1. Medindo a intensidade de associações lineares




2. Soma dos Quadrados e Variância Amostral




2. Soma dos Quadrados e Variância Amostral




2. Soma dos Quadrados e Variância Amostral



2. Soma dos Quadrados e Variância Amostral



2. Soma dos Quadrados e Variância Amostral




Soma dos Quadrados de Y

$$SQ_Y = \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (y_i - \bar{y})(y_i - \bar{y})$$

Variância amostral de Y

$$s_Y^2 = \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n - 1}$$

2. Soma dos Quadrados e Variância Amostral




Soma dos Quadrados de X

$$SQ_X = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})$$

Variância amostral de X

$$s_X^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

3. Soma dos Produtos Cruzados e Covariância




Soma dos produtos cruzados de Y e X

$$SQ_{YX} = \sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})$$

Covariância amostral entre Y e X

$$s_{YX} = \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{n - 1}$$

3. Soma dos Produtos Cruzados e Covariância



Se

$$(y_i - \bar{y}) > 0; (x_i - \bar{x}) < 0$$

ou


$$(y_i - \bar{y}) < 0; (x_i - \bar{x}) > 0$$

temos

$$s_{YX} = \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{n-1} < 0$$

A covariância pode ser **NEGATIVA**

3. Soma dos Produtos Cruzados e Covariância



Se

$$(y_i - \bar{y}) > 0; (x_i - \bar{x}) > 0$$

ou


$$(y_i - \bar{y}) < 0; (x_i - \bar{x}) < 0$$

temos

$$s_{YX} = \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{n-1} > 0$$

A covariância pode ser **POSITIVA**

3. Soma dos Produtos Cruzados e Covariância



Se

$$(y_i - \bar{y}) \approx 0; (x_i - \bar{x}) \approx 0$$

ou

$$(y_i - \bar{y}) \approx 0; (x_i - \bar{x}) \approx 0$$

Temos

$$s_{YX} = \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{n-1} \approx 0$$

A covariância pode ser **NULA**


3. Soma dos Produtos Cruzados e Covariância

Cálculo da covariância entre Y e X

	Y	X	$(y_i - \bar{y})$	$(x_i - \bar{x})$	$(y_i - \bar{y})(x_i - \bar{x})$
1	45.26	5.46	-4.88	-0.95	4.63
2	49.04	6.56	-1.10	0.15	-0.16
3	51.54	5.84	1.40	-0.57	-0.79
4	56.46	7.81	6.32	1.40	8.84
5	48.40	6.38	-1.74	-0.03	0.05
Σ	50.14	6.41	0.00	0.00	12.57


$$s_{YX} = \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{n - 1}$$

$$s_{YX} = \frac{12.57}{5 - 1} = 3.14$$



3. Soma dos Produtos Cruzados e Covariância

Cenários possíveis



O coeficiente de correlação de Pearson

Um pouco de história

Na década de 1890, Karl Pearson foi apresentado a Francis Galton pelo zoólogo Walter Weldon. Juntos fundaram a revista *Biometrika*, com o objetivo de desenvolver teoria em estatística. Galton (primo de Charles Darwin) e Pearson trabalharam juntos em vários problemas relacionados à teoria da evolução, genética, biometria e estatística. Galton trouxe as primeiras ideias sobre a medida de associação entre duas variáveis quantitativas no contexto da hereditariedade e propôs o coeficiente de correlação linear para medir esta associação. Suas ideias foram estendidas por Karl Pearson e Udny Yule para um contexto estatístico mais geral. Pearson trouxe ainda muitas outras contribuições à estatística como o coeficiente de χ^2 e a ideia de *graus de liberdade*. O termo distribuição normal para variáveis com distribuição Gaussiana também surgiu como fruto de seu trabalho (veja em: **Karl Pearson**).



4. O coeficiente de correlação linear de Pearson

Covariância amostral entre Y e X

$$s_{YX} = \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{n - 1}$$

Variância amostral de Y

$$s_Y^2 = \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n - 1}$$

Variância amostral de X

$$s_X^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$


O coeficiente de correlação linear de Pearson r

$$r = \frac{s_{YX}}{\sqrt{s_Y^2} \times \sqrt{s_X^2}}$$

O r de Pearson é a covariância **padronizada** pelos desvios padrões de Y e X

4. O coeficiente de correlação linear de Pearson


A covariância não tem limites negativos ou positivos. A escala depende das magnitudes de Y e de X .



O r de Pearson varia entre -1 e $+1$.

4. O coeficiente de correlação linear de Pearson

$$r = \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{\sqrt{\sum_{i=1}^n (y_i - \bar{y})^2} \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}}$$




- $r = -1$ (Associação linear perfeitamente **negativa**)
- $r = 0$ (Associação linear inexistente)
- $r = 1$ (Associação linear perfeitamente **positiva**)

FIM

class: h1_small

4. Teste de hipóteses sobre o r de Pearson

O r mede associações **lineares**



Correlação **não implica** causalidade

